

Caddie-Nutzerstudie

Studienentwurf zur Masterarbeit

Shared Autonomy - Designing User Oversight for LLM-Based Smartphone Agents

Design	Stichprobe	Dauer
Within-Subjects, drei Aufsichtsstufen	18 auswertbare Personen, Rekrutierung 20-24	ca. 60-75 Minuten

Ziel ist die Untersuchung, wie viel verpflichtende menschliche Aufsicht ein weitgehend autonomer Smartphone-Agent benötigt und wie sich diese Aufsicht auf Aufwand, Beanspruchung, Kontrolle, Aufmerksamkeit und Fehlererkennung auswirkt.

Forschungsfragen

RQ1: Wie beeinflusst der erforderliche Umfang menschlicher Aufsicht den Interaktionsaufwand, die subjektive Beanspruchung und die wahrgenommene Kontrolle bei einem transparenten Smartphone-Agenten?

RQ2: Wie beeinflusst die Kritikalität einer Aufgabe den Zielkonflikt zwischen frei werdender Aufmerksamkeit und rechtzeitiger Fehlererkennung bei reduzierter Aufsicht?

Versuchsbedingungen

Bedingung	Verpflichtende Aufsicht	Eingriff
C1	Bestätigung jeder folgenreichen Aktion	Bestätigen, ändern oder abbrechen
C2	Ein finaler Checkpoint vor der Ausführung	Zusammenfassung ändern oder abbrechen
C3	Keine verpflichtende Bestätigung	Freiwillig pausieren, ändern oder abbrechen

In allen Bedingungen informiert der Agent knapp über die aktuell ausgeführte Aktion. Die Anzeige dient ausschließlich der Beobachtbarkeit und erfordert keine Bestätigung. Der Automatisierungsgrad und die Darstellung bleiben konstant; variiert wird der Umfang der verpflichtenden Aufsicht.

Hypothesen

- **H1:** Erforderliche Nutzeraktionen und aktive Bearbeitungszeit sind in C1 höher als in C2 und C3.
- **H2:** Die subjektive Beanspruchung ist in C1 höher als in C2 und C3; C2 gegenüber C3 wird explorativ betrachtet.
- **H3:** Die wahrgenommene Kontrolle ist in C1 und C2 höher als in C3.
- **H4:** Die Leistung in der parallelen Reaktionsaufgabe steigt mit abnehmender verpflichtender Aufsicht.
- **H5:** Kontrollierte Fehler werden bei stärkerer Aufsicht häufiger beziehungsweise früher erkannt. Der Zusammenhang zwischen Aufgabenkritikalität und gewünschter Aufsicht wird explorativ untersucht.

Kontrollierte Agentenausführung

Die Ausführung wird als kontrollierter Wizard-of-Oz- beziehungsweise Replay-Ablauf umgesetzt. Sämtliche Aktionen, Navigationsschritte, Reaktionszeiten, Fehler und exakten Fehlerzeitpunkte werden vorab definiert. Damit erleben die Teilnehmenden innerhalb einer Aufgabe vergleichbare Abläufe; untersucht wird nicht die tatsächliche Zuverlässigkeit des Sprachmodells.

Fehlerpläne

Jede Person erlebt in drei der sechs Aufgaben einen kontrollierten Fehler. Sechs ausbalancierte Fehlerpläne verteilen die Fehler gleichmäßig über Aufgaben, Bedingungen und Kritikalitätsstufen. Innerhalb eines Blocks können null, ein oder zwei Fehler auftreten, sodass das Auftreten nicht aus dem bisherigen Verlauf ableitbar ist.

Aufgabe	Kontrollierte Abweichung
Musik	Falsche Version eines Liedes
Fotos	Ähnlich benannte, aber falsche Messenger-Gruppe
Kalender	Falsche Uhrzeit oder falscher Erinnerungszeitpunkt
Navigation	Ähnlich benannter, aber falscher Kontakt
Supermarkt	Falsche Produktmenge
Banking	Zahldreher, beispielsweise 18,40 statt 18,04 Euro

Der fehlerhafte Parameter erscheint in C1 in der Schrittbestätigung, in C2 im finalen Checkpoint und in C3 in der laufenden Aktionsanzeige. Erfasst werden Fehlererkennung, Eingriffszeitpunkt, Art des Eingriffs und erfolgreiche Fehlerverhinderung.

Instruktion, Training und Aufklärung

Um keine künstlich erhöhte Fehlersuche auszulösen, werden die kontrollierten Fehler vorab nicht ausdrücklich angekündigt. Die Teilnehmenden erhalten zunächst einige Minuten für eine selbst gewählte, harmlose Aufgabe. Danach werden Korrektur-, Pausen- und Abbruchfunktionen standardisiert geübt, ohne einen Agentenfehler zu demonstrieren. Sie entscheiden anschließend selbst, ob und wann sie eingreifen.

Nach jeder Aufgabe wird neutral gefragt, ob das Ergebnis der ursprünglichen Aufgabenstellung entsprach. Am Ende werden die kontrollierte Ausführung und die eingebauten Abweichungen vollständig erläutert. Das Vorgehen wird hinsichtlich unvollständiger Vorabinformation, Debriefing und möglichem Zurückziehen der Daten ethisch abgestimmt.

Cross-App-Aufgaben

Jede Person bearbeitet sechs Aufgaben. Sie bilden drei Paare aus jeweils einer weniger kritischen und einer kritischeren Aufgabe. Die Zuordnung der Aufgabenpaare zu den Bedingungen und die Reihenfolge der Bedingungen werden ausbalanciert.

Paar	Weniger kritisch	Kritischer
A	Chat -> Musik-App: Drei genannte Lieder zu einer Playlist hinzufügen.	Galerie -> Messenger: Vorbereitete Fotos mit einem Gruß an eine bestimmte Gruppe senden.
B	E-Mail -> Kalender: Terminänderung übertragen und Erinnerung einrichten.	Karten-App -> Messenger: Ankunftszeit mit öffentlichen Verkehrsmitteln bestimmen und an einen Kontakt senden.
C	Chat -> Supermarkt-App: Produkte und Mengen in eine vorbereitete Einkaufsliste übertragen.	E-Mail -> Banking-Mock: Rechnungsdaten übernehmen und eine Überweisung vorbereiten.

Es werden ausschließlich vorbereitete Studienkonten und simulierte Daten eingesetzt. Die Banking-Aufgabe verwendet weder echtes Geld noch persönliche Finanzdaten. Nach jeder Aufgabe wird auf einer siebenstufigen Skala erhoben, wie schwerwiegend die Folgen eines Fehlers eingeschätzt werden.

Messgrößen

Zeitpunkt	Instrument beziehungsweise Messgröße	Zweck
Während der Aufgabe	Bearbeitungszeit, Bestätigungen, Eingriffe, Eingriffszeit, Fehlerverhinderung	Objektives Aufsichts- und Interaktionsverhalten
Während der Aufgabe	Parallele Reaktionsaufgabe: Reaktionszeit und ausgelassene Signale	Frei werdende Aufmerksamkeit
Nach jeder Aufgabe	Wahrgenommene Kritikalität und Übereinstimmung mit der Aufgabenstellung	Manipulationsprüfung und subjektive Fehlererkennung
Nach jeder Bedingung	Raw NASA-TLX; TiA-Subskalen Verständlichkeit/Vorhersagbarkeit und Vertrauen	Beanspruchung, Transparenz und Vertrauen
Nach jeder Bedingung	Drei eigene Einzelitems zu Kontrolle, rechtzeitigem Eingreifen und Angemessenheit der Bestätigungen	Manipulationskontrolle, getrennte Auswertung
Am Studienende	TAM: Perceived Usefulness und Perceived Ease of Use; Präferenz und Kurzinterview	Akzeptanz und qualitative Einordnung

Die Fragebögen werden in Figma als einheitliche Studienfassung gestaltet und ausgedruckt. Wortlaut, Instruktionen und Antwortskalen der Originalinstrumente bleiben erhalten; Instrumente und eigene Items werden klar getrennt. Die Originalfassungen und eine Zuordnung zur Studienfassung werden dokumentiert.

Explorativer Zusatz und technischer Ausblick

Zeitversetzte Agentenaktion

Optional wird untersucht, wie eine nicht unmittelbar, sondern zeitversetzt startende Agentenaktion wahrgenommen wird. Die Aufgabenanweisung lautet: *Prüfe in einer Minute meinen nächsten Kalendertermin und stelle einen Wecker 90 Minuten vorher.* Anschließend werden Komfort, wahrgenommene Kontrolle und der bevorzugte Modus - Benachrichtigung, erneute Rückfrage oder selbstständige Ausführung - erfragt. Bei zu hoher Gesamtdauer entfällt dieser Teil und wird als Ausblick behandelt.

Virtueller Bildschirm

Ein virtueller Bildschirm könnte perspektivisch eine stärker isolierte Agentenausführung ermöglichen. Aufgrund des Implementierungsaufwands ist er keine Voraussetzung für die Hauptstudie, sondern ein möglicher technischer Ausblick. Wahrnehmbare globale Effekte, etwa Lautstärkeänderungen, würden dadurch zudem nicht vollständig verborgen.

Geplanter Ablauf

- Einwilligung, Einführung und demografische Angaben
- Freies Kennenlernen mit einer harmlosen Aufgabe und standardisierte Übung der Eingriffsmöglichkeiten
- Drei ausbalancierte Versuchsblöcke mit jeweils zwei Cross-App-Aufgaben
- Blockweise Fragebögen und aufgabenbezogene Kurzfragen
- Optionaler Test der zeitversetzten Agentenaktion
- Abschließender TAM-Fragebogen, Präferenzabfrage, Kurzinterview und Debriefing

Angestrebt werden 18 vollständig auswertbare Datensätze. Wegen möglicher Abbrüche oder technischer Ausfälle sollen 20-24 Personen rekrutiert werden. Die geplante Dauer von 60-75 Minuten wird vor der Erhebung in Pilotdurchläufen geprüft; der optionale Zusatztest entfällt zuerst, falls die Belastung zu hoch ist.

Zentrale Literatur

Parasuraman, R., Sheridan, T. B., & Wickens, C. D. (2000). *A Model for Types and Levels of Human Interaction with Automation*. IEEE Transactions on Systems, Man, and Cybernetics - Part A, 30(3), 286-297. <https://doi.org/10.1109/3468.844354>

Dahlbäck, N., Jönsson, A., & Ahrenberg, L. (1993). *Wizard of Oz Studies - Why and How*. Knowledge-Based Systems, 6(4), 258-266. [https://doi.org/10.1016/0950-7051\(93\)90017-N](https://doi.org/10.1016/0950-7051(93)90017-N)

Hart, S. G., & Staveland, L. E. (1988). *Development of NASA-TLX: Results of Empirical and Theoretical Research*. In Human Mental Workload. [https://doi.org/10.1016/S0166-4115\(08\)62386-9](https://doi.org/10.1016/S0166-4115(08)62386-9)

Körber, M. (2019). *Theoretical Considerations and Development of a Questionnaire to Measure Trust in Automation*. Advances in Intelligent Systems and Computing, 823, 13-30. https://doi.org/10.1007/978-3-319-96074-6_2

Davis, F. D. (1989). *Perceived Usefulness, Perceived Ease of Use, and User Acceptance of Information Technology*. MIS Quarterly, 13(3), 319-340. <https://doi.org/10.2307/249008>

Deutsche Gesellschaft für Psychologie. *Berufsethische Richtlinien*. <https://www.dgps.de/die-dgps/aufgaben-und-ziele/berufsethische-richtlinien/>