Spickzettel

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Folie 01 · Cold Open: Abgabe der Masterarbeit

Auftrag · Video 1,5× · Freigabe · Handzeichen · Wann prüfen?

Folie 02 · Titel: Shared Autonomy

Andreas · Gemeinsame Kontrolle · Vier Teile

Folie 03 · Agents lernen, Apps zu bedienen

Hersteller · AppAgent · AndroidWorld = Benchmark · DroidRetriever / AgentLens · 30,6 % M3A + GPT-4 Turbo, Accessibility Tree

Folie 04 · Erfolg gemeldet ≠ Erfolg

Eigener Vergleichslauf Mai 2026 · Sechs Aufgaben × 2 · „done“ bei AUS · 11/12

Folie 05 · Nicht ob, sondern wann

Nicht ob · sondern wann · Caddie macht den Moment kontrollierbar

Folie 06 · Der Loop gehört dem Handy

Android vs. Modellrechner · Beobachten · Vorschlagen · Prüfen · Freigabe · Ausführen · Neu beobachten

Folie 07 · Was der PC sieht, ist nicht, was Sie sehen

Erster Prototyp PC + ADB · Verdeckter Button · Accessibility · Ein Gerät

Spickzettel

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Folie 08 · Kritische Aktionen brauchen Freigabe

Vorbereitung läuft · Senden wartet · Freigabe vor Ausführung · Wischen

Folie 09 · Eingreifen: pausieren, korrigieren, weiter

C3-Clip · Hauptbahnhof → Campus Deutz · Pausieren · Korrigieren · Fortsetzen oder beenden · Gestartetes bleibt

Folie 10 · Wo Caddie an Grenzen stößt

Regel erkennt nicht jede Folge · Gestartetes bleibt · Sicht unvollständig · Modell extern

Folie 11 · Wo sitzt der Moment zum Eingreifen?

Bedingung setzt die Gates · C1 jeder konfigurierte Schritt · C2 gebündelt vor dem Commit · C3 keine Pflichtfreigabe · Alle sehen den Ablauf

Folie 12 · Drei Bedingungen nebeneinander

Nachgestellt · C1 Musik · C2 Rechnung · C3 Route · Keine Geschwindigkeits-Rangliste

Folie 13 · Der Auftrag stimmt, ein Wert nicht

Rechnung 30 € · Eingetragen 80 € · Drei Fehler pro Proband

Folie 14 · Die Studie in einem Bild

18 Probanden · 108 Durchgänge · Wie schwerwiegend wäre ein Fehler? Lied ärgerlich, Betrag schwerwiegend · weniger kritisch | kritischer · 54 mit Fehler · Aufsicht, nicht Planung · Within-Design

Spickzettel

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Folie 15 · Sechs Aufgaben, sechs falsche Werte

Zwei Apps je Aufgabe · Weniger kritisch: Route, Notiz, Lied · Kritischer: Kalender, Nicht stören, Zahlung · Test-Apps, kein echtes Geld

Folie 16 · Finden Sie den Fehler

Whiteboard merken · Notiz prüfen · Donnerstag → Dienstag · Erkennen ≠ Korrigieren

Folie 17 · C1 kostet Entscheidungen

Pflichtentscheidung = Antwort auf ein Gate · Mediane 7 / 1 / 0 · C3 kein Gate, nur freiwillig · 13,3 s / 5,6 s · Was bringt der Aufwand?

Folie 18 · Häufiger bestätigen ≠ besser aufpassen

Erwartung abfragen · % = eingebaute Fehler zutreffend berichtet, nur eindeutig auswertbare Fälle · C1 76,5 % · C2 91,7 % · C3 78,6 % · höchste Rate ≠ belegter Vorteil · kein C2-Sieg

Folie 19 · Die Wahl wechselt, wenn es kritischer wird

Ein Punkt = ein Proband · Weniger kritisch 14 × C3 · Kritischer 12 × C1 · 10 wechseln · Allgemein C2

Folie 20 · Was Probanden geschrieben haben

16 Geld-Freigabe · 12 C2 · 11 Last · 11 adaptiv

Folie 21 · Wie weit die Ergebnisse tragen

Kleine Stichprobe: 18 Probanden · Feste Abläufe, ohne LLM · Rückblickende Berichte · Feste Einstufung je Aufgabe

Spickzettel

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Folie 22 · Aufsicht an die Aufgabe anpassen

Häufiger bestätigen: kein belegter Vorteil · Kontrollwunsch wechselt mit der Aufgabe · Regler: Wie schwerwiegend wäre ein Fehler? · C3 → C2 → C1 · Gestaltungsidee, nicht getestet

Folie 23 · Mein Beitrag

Technische Untersuchung · Aufsichtsmechanismus · Kontrollierter Vergleich

Folie 24 · Future Work

Schneller entscheiden → Latenz UND Fehler · Robuster ausführen → Benchmark mit Störungen · Adaptiv → Schattenmodus, dann Studie

Folie 25 · Diese Entscheidung bleibt bei mir

Gleiche Mail · Vorbereitung vs. Senden · Entscheidung beim Menschen

Folie 26 · Danke und Fragen

Danke · Fragen · Backups mit G

Backups für Rückfragen

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Backup B1 · Modellaufruf

Protokoll + Tools → Gateway → Modellrechner → ein Tool-Aufruf · Instruktion ist keine Grenze

Backup B2 · Datenfluss

Modellrechner bekommt Beobachtungen ohne Passwortfelder · MCP-Argumente · Spracherkennung · Selbst gehostet ≠ privat

Backup B3 · Sprache

„Hey Jarvis“ auf dem Handy · Android-Spracherkennung · Stopp / Korrektur / Kontext löschen · an den Lauf gebunden

Backup B4 · Wischen zum Bestätigen

Mindestens 75 % der Strecke · Bewusste Hürde · Nicht gegen Tippen getestet

Backup B5 · Fehler und Recovery

Journal vor Dispatch · Einmal ausführen · Unklar → Pause · Studie: zurückspulen oder ablehnen · 17 Korrekturketten

Backup B6 · Retrieval-Evaluation

Pilot 7 Skills: 70 % vs. 20 % · Navigationshinweise 12/18 vs. 12/18 · Finaler Korpus nicht evaluiert

Backup B7 · Memory-Kontrolle

Nach der Studie ergänzt · Sichtbar, änderbar, löschbar · Nur vier Vorlieben automatisch · Keine Erlaubnis · Nicht gemessen

Backups für Rückfragen

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Backup B8 · MCP

Gleiche Registry · Handy bleibt lokal · Gleiche Prüfung · Nur JSON-Objekt geprüft · Studie ohne MCP

Backup B9 · GUI-Alternativen

Abkürzungen 59 → 19 s / 22 → 16 s · Erfolg gleich · AppFunctions + Accessibility als Rückfall

Backup B10 · Jev: Future Work zur Latenz

Neuer Ausblick · Jev wählt typisiert aus Kandidaten · LLM für offene Fälle · Android prüft weiter · Latenz UND Fehler messen

Backup B11 · Methodik

18 Slots · Kein LLM im Messlauf · Separation → Bayes · Klick 1: Zählungen 35 / 8 / 11 · Klick 2: nicht zuordenbar, Sensitivität [−8; +35] · Keine Präregistrierung behaupten

Backup B12 · Präferenzen: weniger kritisch → kritischer

Zeilen weniger kritisch · Spalten kritischer · Zehn C3 → C1 · Beschreibend

Backup B13 · Belastung (Raw NASA-TLX)

21,25 / 16,85 / 19,81 · C2 deskriptiv niedriger · p = .433 · Keine Gleichwertigkeit

Backup B14 · Was an der Demo echt ist

Echter Sprachstart und Android · Feste Aktionsfolge · Nicht gesendet

Backups für Rückfragen

Shared Autonomy · v4.1 · Anker für das freie Sprechen

Backup B15 · Bei kritischeren Aufgaben häufiger berichtet

Dieselben Fehlerfälle wie Folie 18, nach Einstufung der Aufgabe gruppiert · weniger kritisch 68,2 % · kritischer 95,2 % · Sicherheit hängt von der Auswertung ab

Backup B16 · Die Lücke: Wann soll ich prüfen?

Qualitative Karte · Umgebung · Zeitpunkt verglichen · Caddie

Backup B17 · Warum nicht einfach …?

PC → App · Mehrere Aktionen → ein geprüfter Schritt · Prompt → Gate · „fertig“ → Beobachtung

Backup B18 · Skills, Retrieval und Memory

„Bildschirm dunkel“ · Skill über Bedeutung · Memory = heute ergänzt, nicht untersucht · Hinweise ≠ Erlaubnis

Backup B19 · Alltag und Studie getrennt

Alltag: Modell schlägt vor, Regel → Freigabe · Studie: feste Abläufe, kein LLM · C1 konfigurierte Schritte · C2 gebündelt vor Commit